



重庆大学
CHONGQING UNIVERSITY

《机器学习基础》 *Machine Learning*

课程复习

重庆大学计算机学院 何中市

Email: zshe@cqu.edu.cn

<https://faculty.cqu.edu.cn/ZhongshiHe/>



课程目标

✓ 目标

- 介绍机器学习核心算法+理论 (基础理论与实践的均衡): 理论上=利用统计学+计算机复杂性+贝叶斯分析的理论成果回答”学习性能怎样随着给定训练样本数量而变化”+”对于各种不同的学习任务, 哪个学习算法最合适”等问题; 实践上=介绍该领域一些主要算法+算法的运行过程.
- 从相关学科(统计学/人工智能/哲学/信息论/生物学/认知科学/计算复杂性理论等)的角度理解机器学习问题的背景-算法-假定
- 内容包括概念学习/决策树学习/神经网络等系列函数逼近方法, 支持向量机、贝叶斯网络等统计学习方法, 以及假设评估等理论问题.
- 掌握现代机器学习方法的思想、动机、原因与做法。



主要内容介绍：周志华的专著

主要参照-周志华的专著《机器学习》，主要章节内容如下：

机器学习绪论、模型评估与选择，主要的监督学习模型如决策树、神经网络、支持向量机等，操作概率的贝叶斯方法，非监督学习聚类方法，特征降维方法与半监督学习，计算学习等。

第1章 绪论=学习问题：假设空间-归纳偏好

实例：西瓜问题

第2章 学习模型评估与选择

第3章 线性模型 算法：

第4章 决策树 实例： 算法：



第5章 神经网络 例：

算法：

第6章 支持向量机

第7章 贝叶斯分类器

第8章 集成学习

第9章 聚类

第10章 降维与度量学习

:

算法：

实例：

算法：





成绩评定

✓ 成绩评定方案

期末:60%

平时:40%

期末考试: 2小时 (60%)

平时成绩: 课后习题+课堂交流 (10%)

实践项目: 实验4个 (30%)



一、课程复习

- 总体要求

- 模型评估，知识图谱，植树造林，学习技术。
- 问题描述，概念思路，算法步骤，计算题目。

- 题目类型@2020

- 问题描述： ...
- 概念关系： ...
- 算法步骤： ...
- 计算问题：最小二乘分析、决策树有剪枝、两层感知机/器、贝叶斯k均值，概率频率计算须重视。



一、课程复习

- 总体要求

- 模型评估，知识图谱，植树造林，学习技术。
- 问题描述，概念思路，算法步骤，计算题目。

- 题目类型@2024?



课程复习

十章要点

- 绪论：假设空间、归纳偏好
- 评估选择：评估方法、性能指标
- 线性模型：回归估计、最小二乘
- 决策树：分支属性、纯度指标，随机森林，三个代表
择优生根、偏好剪枝。
- 神经网络：感知神经、超乎线性，BP算法，网络模型
- 支持向量机：泛化误差、间距最大，支持向量、变换核化
- 贝叶斯分类器：后验风险、极大似然，朴素贝斯、条件独立
- 集成学习：
以弱生强集成道、重启自助依赖少，组合策略重权衡、学习平均可投票。
分类回归CART树、基尼指数小纯度，样本属性求多样、随机森林采自助
- 聚类：非监学习、相似相异、原型密度、划分层次：距离相似
- 降维：k多维缩放MDS，主成分分析PCA，流形学习Isomap、LLE



课程复习参考题目

• 九章要点

- 绪论：假设空间、归纳偏好
 - 监督学习和非监督学习，分类和回归问题的联系与区别。
- 评估选择：评估方法、性能指标
 - 欠拟合与过拟合现象
 - 偏差（bias）和方差（variance）解释
- 线性模型：回归估计、最小二乘
 - 计算公式： $\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$
- 决策树：分支属性、纯度指标，随机森林，三个代表
 - 择优生根、偏好剪枝。
 - 计算公式：信息熵，信息增益...
 - 决策树时如何将连续属性离散化



课程复习参考题目

• 九章要点

- 神经网络：感知神经、超乎线性，BP算法，网络模型
 - 神经网络构成要素？BP网络的拓扑结构（单隐层|两层感知机）
 - 感知机、线性单元与Sigmoid单元的异同何在？
 - 采用标准BP算法实现一次前向训练：2*2*2，X-B-Y，权重W-V，阈值 θ - γ ：
 - 计算公式：@前馈 $S = X^T W - \theta$, $B = f(S)$; $L = B^T V - \gamma$, $C = f(L)$;
@反馈 $E_k = 0.5(\|Y - C\|_2)^2$
- 支持向量机：泛化误差、间距最大，支持向量、变换核化
 - 支持向量机的思想是什么？支持向量机的原理
 - 支持向量机中为什么引入核函数？
 - 支持向量机的形式化描述模型及其等价的对偶问题。
- 贝叶斯分类器：后验风险、极大似然，朴素贝斯、条件独立
 - 计算公式。
 - 利用贝叶斯法则计算事件的概率（实例）



课程复习参考题目

• 九章要点

- 集成学习：以弱生强集成道、重启自助依赖少，组合策略重权衡、学习平均可投票。
 - 分类回归CART树、基尼指数小纯度，样本属性求多样、随机森林采自助
 - 随机森林的生成方法以及其随机性体现在哪里？
- 聚类：非监学习、相似相异、原型密度、划分层次
 - 计算公式：距离。K均值算法进行聚类
 - 选择一种原型聚类方法，描述其算法思想、步骤与算法流程
- 综合交叉
 - 基于最小平方误差原则的人工神经网络学习与贝叶斯学习有何联系？
 - 聚类任务及聚类算法的原则
 - 聚类-&分类的融合：一机器学习任务包含一部分有标注数据，也包含一部分没有标注的数据，为尽量利用好这些数据，设计一个解决这个任务的机器学习方案。



一个医疗诊断问题

- 有两个可选的假设：病人患癌症、病人未患癌症
- 可用数据来自 检验结果：阳性+ 阴性-
- 有先验知识：在所有人人口中，患病率是0.008，对确实患病的患者的检验准确率为98%，对确实未患病的病人的检验准确率为97%
 - 假定有一个新病人，检验结果为阳性，是否应将病人断定为患癌症？
- 总结如下
 - 求后验概率： $P(\text{cancer}|+)$ 和 $P(\neg\text{cancer}|+)$
 - 已知 $0.008=?$ $98%=?$ $97%=?$



一个医疗诊断问题

- 有两个可选的假设：病人患癌症、病人未患癌症
- 可用数据来自 检验结果：阳性+ 阴性-
- 有先验知识：在所有人口中，患病率是0.008，对确实患病的患者的检验准确率为98%，对确实未患病的病人的检验准确率为97%
 - 假定有一个新病人，检验结果为阳性，是否应将病人断定为患癌症？
- 总结如下
 - 求后验概率： $P(\text{cancer}|+)$ 和 $P(\neg\text{cancer}|+)$
 - 已知 $0.008=?$ $98%=?$ $97%=?$
 $P(\text{cancer})=0.008$, $P(\neg\text{cancer})=0.992$
 $P(+|\text{cancer})=0.98$, $P(-|\text{cancer})=0.02$
 $P(+|\neg\text{cancer})=0.03$, $P(-|\neg\text{cancer})=0.97$



一个医疗诊断问题

- 问题：假定有一个新病人，化验结果为正，是否应将病人断定为有癌症？求后验概率 $P(\text{cancer}|+)$ 和 $P(\neg\text{cancer}|+)$
- 利用公式(6.2)找到极大后验假设
 - $P(+|\text{cancer})P(\text{cancer})=0.0078$
 - $P(+|\neg\text{cancer})P(\neg\text{cancer})=0.0298$
 - $h_{\text{MAP}}=\neg\text{cancer}$
- 确切的后验概率可将上面的结果归一化以使它们的和为1
 - $P(\text{cancer}|+)=0.0078/(0.0078+0.0298)=0.21$
 - $P(\neg\text{cancer}|+)=0.79$
- 贝叶斯推理的结果很大程度上依赖于先验概率，另外不是完全接受或拒绝假设，只是在观察到较多的数据后增大或减小了假设的可能性

$P(+)=?$



问题-概念

- 简述有监督学习与无监督学习的概念，列举出对应的至少一种算法模型。
- 解释“欠拟合”、“过拟合”这两个名词概念，并给出解决这两种问题的主要解决方案（每个问题至少一种）。
- 使用机器学习的方法训练模型时，要考虑合理的训练集和测试集，阐述留出法、K折交叉验证法与自助法的原理。
- 决策树的预剪枝与后剪枝各有什么优缺点？
- 谈谈你对核函数的理解（从定义、基本思想、常见核函数的选择等至少两个角度）



问题-概念

- 请简述什么是假设空间，什么是版本空间。
- 请简述训练误差、测试误差、泛化误差。
 - 训练误差小的时候，泛化误差就一定小吗？
- 对数几率回归解决的是回归问题还是二分类问题？
 - 训练对数几率回归的方法是什么？
- 朴素贝叶斯分类器解决了什么障碍？其关键假设是什么？
- 请简述局部极小与全局极小。
-



问题-思考

- 给出 **k 均值聚类** 算法的伪代码描述。
- 集成学习方法包括 **bagging** 和 **boosting** 两个大类，阐述 **bagging** 方法和 **boosting** 方法的基本原理，并对比两者在偏差-方差分解角度的主要关注点。
- **支持向量机** 基本型解决的是回归问题还是二分类问题？如果超平面不可以将训练样本正确分类，支持向量机基本型方法还可以用吗？如果不可以用，有哪些改进方法？这些改进方法的基本原理是什么？
- **集成** 一定能提升性能吗？影响集成学习的性能的关键因素有哪些，以及是如何影响的？请列举1个可以提高集成学习性能的方法。



问题-算法

- 1. 请为以下k均值算法的步骤1, 5, 6, 7, 10添加注释.

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
聚类簇数 k .

过程:

- 1: $\{\mu_1, \mu_2, \dots, \mu_k\}$
- 2: **repeat**
- 3: 令 $C_i = \emptyset$ ($1 \leq i \leq k$)
- 4: **for** $j = 1, 2, \dots, m$ **do**
- 5: $d_{ji} = \|\mathbf{x}_j - \mu_i\|_2$;
- 6: $\lambda_j = \arg \min_{i \in \{1, 2, \dots, k\}} d_{ji}$;
- 7: $C_{\lambda_j} = C_{\lambda_j} \cup \{\mathbf{x}_j\}$;
- 8: **end for**
- 9: **for** $i = 1, 2, \dots, k$ **do**
- 10: $\mu'_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$;
- 11: **if** $\mu'_i \neq \mu_i$ **then**
- 12: 将当前均值向量 μ_i 更新为 μ'_i
- 13: **else**
- 14: 保持当前均值向量不变
- 15: **end if**
- 16: **end for**
- 17: **until** 当前均值向量均未更新

输出: 簇划分 $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$

k 均值算法



问题-算法

- 请为以下决策树算法的步骤3, 6, 8, 12添加伪代码。

输入: 训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$;
属性集 $A = \{a_1, a_2, \dots, a_d\}$.
过程: 函数 TreeGenerate(D, A)

- 1: 生成结点 node;
- 2: **if** D 中样本全属于同一类别 C **then**
- 3:
- 4: **end if**
- 5: **if** $A = \emptyset$ **OR** D 中样本在 A 上取值相同 **then**
- 6:
- 7: **end if**
- 8:
- 9: **for** a_* 的每一个值 a_*^v **do**
- 10: 为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;
- 11: **if** D_v 为空 **then**
- 12:
- 13: **else**
- 14: 以 TreeGenerate($D_v, A \setminus \{a_*\}$) 为分支结点
- 15: **end if**
- 16: **end for**

输出: 以 node 为根结点的一棵决策树



问题-计算

- 一个 **BP 神经网络** 为两层结构: ...
- 试**画出该 BP 网络的拓扑结构**; **画图-手工**
- 请写出隐含层各神经元的输入和输出、输出层各神经元的输入和输出。

1、(10 分) 一个 BP 神经网络为两层结构, 网络的输入模式为 X , 期望输出模式为 Y , 输入层至隐含层的初始连接权重 W 、隐含层至输出层的初始连接权重 V 、隐含层神经元的阈值 θ 和输出层神经元的阈值 γ 如下:

$$X = \begin{pmatrix} 1 \\ 3 \end{pmatrix} \quad Y = \begin{pmatrix} 0.95 \\ 0.95 \end{pmatrix} \quad W = \begin{pmatrix} 1 & 2 \\ -2 & 0 \end{pmatrix} \quad V = \begin{pmatrix} 1 & 1 \\ 0 & -2 \end{pmatrix} \quad \theta = \begin{pmatrix} 3 \\ -1 \end{pmatrix} \quad \gamma = \begin{pmatrix} -2 \\ 3 \end{pmatrix}$$

(1) 试画出该 BP 网络的拓扑结构。

(2) 采用标准 BP 算法实现对该 BP 网络的一次前向训练(激活函数为 Sigmoid 函数), 请写出隐含层各神经元的输入和输出、输出层各神经元的输入和输出。(注:

$e^{-3} \approx 0.050$, $e^{-2} \approx 0.14$, $e^{4.9} \approx 134.29$, $e^6 \approx 403.43$, $e^7 \approx 1096.63$, $e^8 \approx 2981.00$)

Sigmoid 函数的公式为:

$$S(x) = \frac{1}{1 + e^{-x}}$$



问题-计算

- 输出层各神经元的输入和输出。

画图-手工

$$X = \begin{pmatrix} 1 \\ 3 \end{pmatrix} \quad Y = \begin{pmatrix} 0.95 \\ 0.95 \end{pmatrix} \quad W = \begin{pmatrix} 1 & 2 \\ -2 & 0 \end{pmatrix} \quad V = \begin{pmatrix} 1 & 1 \\ 0 & -2 \end{pmatrix} \quad \theta = \begin{pmatrix} 3 \\ -1 \end{pmatrix} \quad \gamma = \begin{pmatrix} -2 \\ 3 \end{pmatrix}$$

- 隐藏层: $S = W^T X - \theta$, $B = f(S)$

$$s_1 = w_{11}x_1 + w_{21}x_2 - \theta_1 = 1*1 + (-2)*3 - 3 = -8, b_1 = f(s_1) = 1/(1 + e^8) \approx 0.00034$$

$$s_2 = w_{12}x_1 + w_{22}x_2 - \theta_2 = 2*1 + 0*3 - (-1) = 3, b_2 = f(s_2) = 1/(1 + e^{-3}) \approx 0.95$$

- 输出层: $L = V^T B - \gamma$, $C = f(L)$

$$l_1 = v_{11}b_1 + v_{21}b_2 - \gamma_1 = 1*0.00034 + 0*0.95 - (-2) \approx 2.00$$

$$c_1 = f(l_1) = 1/(1 + e^{-2}) \approx 0.88$$

$$l_2 = v_{12}b_1 + v_{22}b_2 - \gamma_2 = 1*0.00034 + (-2)*0.95 - 3 \approx -4.90$$

$$c_2 = f(l_2) = 1/(1 + e^{4.9}) \approx 0.0074$$



问题-计算

- **混淆矩阵**：假设某小区进出 100 人，其中 80 人未感染C病毒，20 人感染C病毒，社区需要将这些感染者检测出来。采用A,B两种检测试剂检测，试剂 A , B 的检测表现如下表所示。
 - 请计算A,B两种检测试剂**查准率与查全率**
 - 并判断在该场景下，哪个检测试剂的表现**更好一些**？

检测实际A的表现（混淆矩阵）

真实情况/检测出	阳性	阴性	合计
感染者	5	15	20
未感染着	1	79	80
	6	94	100

检测实际B的表现（混淆矩阵）

检测出/实际上	实际感染者	实际未感染着	合计
检测阳性	10	10	20
检测阴性	20	60	70
	30	80	100



问题-计算

- 决策树：P76
 - 一批西瓜/表4.1，判断好坏的决策树
- 朴素贝叶斯分类器：P151
 - 一个西瓜/测1，判断好坏





问题-计算

- 朴素贝叶斯分类器：仓库中有一批服装，为了更好的销售，需要根据服装的款式 X_1 （1：上衣；2：裤子）和尺码 X_2 （S：小码；M：中码；L：大码）对这批服装进行类别标记（1：打折销售；-1：不打折）。因此，每一件服装样本有两个属性 X_1 , X_2 ，样本类别标记使用 Y 表示，数据如表 3。
- 问题：若有一个服装样本（裤子，小码） $x=[2,S]$ ，请使用朴素贝叶斯分类器模型预测该样本的类别（打折销售还是不打折销售？）

表 3

X_1	X_2	Y
1	S	-1
1	M	-1
1	S	1
1	S	-1
2	M	-1
2	L	1
2	L	1
3	L	1
3	M	1
3	M	1
3	L	1
3	L	-1



二、习题解疑

- 1.2 求假设空间大小
- 最多包含 k 个合取式的析合范式-可能的假设数不超过

$$\text{Sum}\{C(48, i), i=1 \dots k\}$$

1.2 与使用单个合取式来进行假设表示相比, 使用“析合范式”将使得假设空间具有更强的表示能力. 例如

$$\begin{aligned} \text{好瓜} \leftrightarrow & \left((\text{色泽} = *) \wedge (\text{根蒂} = \text{蜷缩}) \wedge (\text{敲声} = *) \right) \\ & \vee \left((\text{色泽} = \text{乌黑}) \wedge (\text{根蒂} = *) \wedge (\text{敲声} = \text{沉闷}) \right), \end{aligned}$$

会把“(色泽=青绿) $\wedge$ (根蒂=蜷缩) $\wedge$ (敲声=清脆)”以及“(色泽=乌黑) $\wedge$ (根蒂=硬挺) $\wedge$ (敲声=沉闷)”都分类为“好瓜”. 若使用最多包含 k 个合取式的析合范式来表达表 1.1 西瓜分类问题的假设空间, 试估算共有多少种可能的假设.



习题解疑

– 3.2 证明函数凹凸性

3.2 试证明, 对于参数 w , 对率回归的目标函数(3.18)是非凸的, 但其对数似然函数(3.27)是凸的.

$$y = \frac{1}{1 + e^{-(w^T x + b)}} \ell(\beta) = \sum_{i=1}^m \left(-y_i \beta^T \hat{x}_i + \ln \left(1 + e^{\beta^T \hat{x}_i} \right) \right)$$

– 解题关键点有三

- 凸函数判定: 定义/充要条件
- 多元函数梯度/偏导数: 矩阵相乘的阶数-转置与否有意义

– 教材笔记

对于式3.27, 关于 β 的二阶导有 (原书p60)

$$\frac{\partial^2 l(\beta)}{\partial \beta \partial \beta^T} = \sum_{i=1}^m \tilde{x}_i \tilde{x}_i^T p_1(\tilde{x}_i; \beta)(1 - p_1(\tilde{x}_i)) = X P X^T, \text{ 其中第一个等号是原书中的,}$$

第二个等号中 X 为 (n, m) 矩阵, 每一列对应一个样本, P 为对角矩阵,

$$P_{ii} = p_1(\tilde{x}_i; \beta)(1 - p_1(\tilde{x}_i)).$$



习题解疑

– 3.7 最优的ECOC

3.7 令码长为 9, 类别数为 4, 试给出海明距离意义下理论最优的 ECOC 二元码并证明之.

答案: 当码长为 $2^{d-1}-1$ 时, 至少可以使 d 个类别达到最优间隔 d , 其的海明距离为 2^{d-2} 。

穷举编码“exhaustive codes”:

第 1 行: $2^{d-1}-1$ 个“1”

第 2 行: 2^{d-2} 个“0”, 之后是 $2^{d-2}-1$ 个“1”

第 3 行: 2^{d-3} 个“0”, 之后是 2^{d-3} 个“1”, 继续至结尾

...

第 d 行: 1 个“0”, 之后是 2^{d-3} 个“1”, 继续至结尾

– 取 $d=4$, 则码长为 7, 类别数为 4, 间隔至少为 4。如下:

	f0	f1	f2	f3	f4	f5	f6
c1	1	1	1	1	1	1	1
c2	0	0	0	0	1	1	1
c3	0	0	1	1	0	0	1
c4	0	1	0	1	0	1	0



习题解疑

- 5.7 根据式5.18和5.19，试构造一个能解决异或问题的单层RBF神经网络。

$$\varphi(\mathbf{x}) = \sum_{i=1}^q w_i \rho(\mathbf{x}, \mathbf{c}_i) \quad \text{..... (5.18) ,}$$

$$\rho(\mathbf{x}, \mathbf{c}_i) = e^{-\beta_i \|\mathbf{x} - \mathbf{c}_i\|^2} \quad \text{..... (5.19)}$$

使用4个训练样本： $\mathbf{X} = \text{array}([[1, 0], [0, 1], [0, 0], [1, 1]])$ ，
 $\mathbf{y} = \text{array}([[1], [1], [0], [0]])$ 作为数据，训练一个RBF神经网络。
使用均方根误差作为损失函数。

输出层为隐藏层的线性组合（且另外加上了一个偏置项）。

按照公式，假设2个隐藏层节点 $q=2$ ，利用BP算法求解优化问题均方误差最小化

参数个数： $2(2+1)=6$ 个参数，优化问题BP算法



习题解疑

- 6.7 试给出式 (6.52) 的完整 KKT 条件。
- 对应着原书式6.47-6.50 & 6.52合并之

$$w = \sum_i (\alpha'_i - \alpha_i) x_i$$

$$0 = \sum_i (\alpha'_i - \alpha_i)$$

对所有的 i

$$C = \alpha_i + u_i$$

$$C = \alpha'_i + u'_i$$

$$\alpha_i (f(x_i) - y_i - \varepsilon - \xi_i) = 0$$

$$\alpha'_i (y_i - f(x_i) - \varepsilon - \xi'_i) = 0$$

$$(C - \alpha_i) \xi_i = 0$$

$$(C - \alpha'_i) \xi'_i = 0$$



习题解疑

- 7.1 极大似然法估算类条件概率
- 试使用极大似然法估算西瓜数据集3.0中前3个属性的类条件概率

表 4.3 西瓜数据集 3.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

色泽:

$P(\text{青绿}|\text{好瓜})=3/8, P(\text{青绿}|\text{坏瓜})=3/9$

$P(\text{乌黑}|\text{好瓜})=4/8, P(\text{乌黑}|\text{坏瓜})=2/9$

$P(\text{浅白}|\text{好瓜})=1/8, P(\text{浅白}|\text{坏瓜})=4/9$

根蒂:

$P(\text{蜷缩}|\text{好瓜})=5/8, P(\text{蜷缩}|\text{坏瓜})=3/9$

$P(\text{稍蜷}|\text{好瓜})=3/8, P(\text{稍蜷}|\text{坏瓜})=4/9$

$P(\text{硬挺}|\text{好瓜})=0/8, P(\text{硬挺}|\text{坏瓜})=2/9$

敲声:

$P(\text{浊响}|\text{好瓜})=6/8, P(\text{浊响}|\text{坏瓜})=4/9$

$P(\text{沉闷}|\text{好瓜})=2/8, P(\text{沉闷}|\text{坏瓜})=3/9$

$P(\text{清脆}|\text{好瓜})=0/8, P(\text{清脆}|\text{坏瓜})=2/9$



习题解疑

— 7.7 AODE估算先验概率项 $P(c, x_i)$ 所需的样例数

7.7 给定 d 个二值属性的二分类任务, 假设对于任何先验概率项的估算至少需 30 个样例, 则在朴素贝叶斯分类器式(7.15)中估算先验概率项 $P(c)$ 需 $30 \times 2 = 60$ 个样例. 试估计在 AODE 式(7.23)中估算先验概率项 $P(c, x_i)$ 所需的样例数(分别考虑最好和最坏情形).

最好情况:

每一类的每个属性都一致, 则需要 $30 \times 2 = 60$ 个样例。

最坏情况: 需要 $30 \times 2 \times d = 60d$ 个样例



习题解疑

– 9.1 证明：闵可夫斯基距离满足距离度量的四条基本性质否？

9.1 试证明： $p \geq 1$ 时，闵可夫斯基距离满足距离度量的四条基本性质；
 $0 \leq p < 1$ 时，闵可夫斯基距离不满足直递性，但满足非负性、同一性、对称性； p 趋向无穷大时，闵可夫斯基距离等于对应分量的最大绝对距离，即

$$\lim_{p \rightarrow +\infty} \left(\sum_{u=1}^n |x_{iu} - x_{ju}|^p \right)^{\frac{1}{p}} = \max_u |x_{iu} - x_{ju}|.$$

– 利用闵可夫斯基不等式证明 $\left(\sum_{i=1}^n (x_i + y_i)^p \right)^{\frac{1}{p}} \leq \left(\sum_{i=1}^n x_i^p \right)^{\frac{1}{p}} + \left(\sum_{i=1}^n y_i^p \right)^{\frac{1}{p}}$

$p \geq 1$ 时：三角不等式，证明“利用闵可夫斯基不等式”

$p < 1$ 时：三角不等式不满足，利用“利用闵可夫斯基不等式”：

举反例，只要点坐标慢则和的两项都非负，就可以。

p 趋向于无穷大时：

$$(M^p)^{1/p} < d < (nM^p)^{1/p} \Rightarrow \text{极限 } M < \lim d < \lim (nM^p)^{1/p} = M,$$

夹逼准则



三、大纲

- 教学大纲
 - 教材前11章
- 考试大纲
 - 1.成绩构成
 - 考核方式 总分 占总成绩的比例
 - 课堂教学 100分 60%
 - 实践项目 5分/项目，共4个项目 20%
 - 分组讨论/平时作业 10分 10%
 - 项目代码 2.5分/项目，共4个项目 10%



四、2024年题目

- 一、选择题（每空2分，共20分）
- 二、简答题（共40分，每小题10分）
- 三、计算题（30分，每小题15分）
- 四、思考题（10分）





2024年题目

- 一、选择题（每空2分，共20分）
- 二、简答题（共40分，每小题10分）
 - 1、请对比假设空间与版本空间的区别。（10分）
 - 2、在机器学习领域，我们经常要求解目标函数的最小值，请列出学过的至少2个求解最小值的方法，并做简单解释说明。（10分）
 - 3、请简述样本类别不平衡问题的概念及解决方法。（10分）
 - 4、请简述回归树的基本原理并且说明其与决策树的区别。（10分）
- 三、计算题（30分，每小题15分）
- 四、思考题（10分）



2024年题目

- 一、选择题（每空2分，共20分）
- 二、简答题（共40分，每小题10分）
- 三、计算题（30分，每小题15分）

1、（15分）如下8个样本点聚为三类： $A1(1,2)$ 、 $A2(3,1)$ 、 $A3(8,4)$ 、 $B1(5,8)$ 、 $B2(4,1)$ 、 $B3(6,4)$ 、 $C1(3,5)$ 、 $C2(4,9)$ ，距离函数是欧氏距离，并假设初始中心为 $A1$ ， $B1$ ， $C1$ 。采用K均值算法，求在第一次循环后的三个聚类组成及相应的聚类中心。

2、（15）假设给定有图的数据集，其中 A, B, C 为二值随机变量， Y 为标记（预测值）。根据给定的训练集，使用朴素贝叶斯分类器计算 $A=0$ ， $B=0$ ， $C=1$ 的预测值。

- 四、思考题（10分）



2024年题目

- 一、选择题（每空2分，共20分）
- 二、简答题（共40分，每小题10分）
- 三、计算题（30分，每小题15分）
- 四、思考题（10分）

针对下面学习模型泛化能力差的情况，分析其导致的原因并以决策树和神经网络为例给出具体的解决方案：

- （1）学习模型在训练集中预测精度低，对未知样本预测精度低；
- （2）学习模型在训练集中预测精度高，对未知样本预测精度低。



课程复习-CAC

• CAC-沁园春·机器学习/1

- 上阕
 - 算法争锋，千兆数据，万卷浪涛。
 - 看线性回归，权重分明；决策分枝，规则如刀。
 - 深网层峦，卷积激荡，欲与人工试比高。
 - 须晴日，见梯度流转，误差尽消。
- 下阕
 - 模型如此多娇，引无数学者竞折腰。
 - 惜贝叶斯朴素，独立性扰；SVM悍，核选煎熬。
 - 一代天骄，强化试错，只识奖惩作剑鞘。
 - 俱往矣，数智能之道，还看今朝！



课程复习-CAC

• CAC-沁园春·机器学习/2

- 上阕
 - 算法争锋，千兆数据，万卷浪涛。
 - 看线性回归，权重分明；决策分枝，规则如刀。
 - 万木竞秀，梯度叠潮，集成森罗镇九霄。
 - 更识得，星聚类分，密网捞。
- 下阕
 - 模型如此多娇，引无数学者竞折腰。
 - 惜贝叶斯朴素，独立性扰；SVM悍，核选煎熬。
 - 昔单木易凋，今林海傲，试问过拟合谁可逃？
 - 俱往矣，数智能之道，还看今朝！



9章内容：提炼关键特色

模型	核心思想	突出特色	典型应用场景	实例联想	优势/劣势对比
线性模型	线性 加权组合 预测	可 解释性强 ，参数权重可视化	结构化 数据回归 /二分类	房价预测 （线性回归）	✓ 计算高效 ✗ 难处理非线性数据
决策树	递归 特征划分 的 树形结构	直观的"if-else"规则，支持类别特征	客户分群/ 医疗诊断	鸢尾花分类 （ID3/C4.5）	✓ 可解释 ✗ 易过拟合
神经网络	多层非线性 变换拟合复杂函数	端到端特征学习， 强大的表征能力	图像识别/ 自然语言处理	MNIST手写识别 （MLP/CNN）	✓ 高拟合度 ✗ 需大量数据/算力
SVM	最大化分类间隔 的核技巧方法	凸优化保证 全局最优 ，核函数处理非线性	小样本高维 数据分类	文本分类 （RBF核）	✓ 泛化强 ✗ 核选择敏感
贝叶斯分类器	贝叶斯定理与特征 条件独立 假设	概率框架 下的增量学习，抗噪声能力强	垃圾邮件过滤	新闻分类 （多项式朴素贝叶斯）	✓ 高效训练 ✗ 独立性假设限制
集成学习	多模型组合 提升泛化性能	Bagging 降方差， Boosting 减偏差	竞赛型 复杂任务	金融风控 （随机森林/XGBoost）	✓ 强泛化 ✗ 计算复杂度高
聚类	无监督数据 内在结构 发现	无需标签 的群体划分能力	用户画像构建	客户分群 （K-means/DBSCAN）	✓ 探索性分析 ✗ 需预设聚类数
特征选择	LASSO/岭回归等稀疏化方法	自动特征筛选 ， 缓解维度灾难	高维 生物信息 数据	基因筛	✓ 提高泛化 ✗ 可能损失重要特征